# Tipología y ciclo de vida de los datos

## PRA2: Limpieza y análisis de los datos


Germán del Cacho Salvador
Enrique Callejas Castro
Mayo de 2022
Máster Universitario de Ciencia de Datos

# Índice

1. Descripción del dataset ..... 3
2. Integración y selección de los datos de interés a analizar ..... 4
3. Limpieza de datos ..... 6
4. Análisis de datos ..... 8
5. Resolución del problema ..... 14
6. Referencias y contribuciones ..... 15

# 1. Descripción del dataset

En los últimos años, los alojamientos turísticos de particulares se han popularizado. La expansión de plataformas como Airbnb han tenido un impacto importante en la sociedad, por lo que resulta fundamental desarrollar nuevas herramientas que permitan comprender este nuevo mercado.

El presente proyecto tiene como objetivo el preprocesado y un primer análisis de un conjunto de datos de la plataforma Airbnb, referente a alojamientos situados en Washington DC. En el presente informe se exponen los principales resultados acompañados de los fragmentos de código más relevantes en los procesos de preprocesado y análisis. El código completo se encuentra en el archivo *.ipynb* del repositorio.

Nos hemos propuesto: (1) **localizar los barrios más caros y baratos**; (2) **conocer cuáles son las variables que más impactan en el precio del alojamiento;** y (3) desarrollar un modelo que permita **predecir el precio** de un nuevo alojamiento.

La primera exploración del archivo elegido (tidy_dc_airbnb.csv) nos permite ver que cuenta con un total de 3671 filas y 19 columnas. Después de una primera exploración, se ha identificado el significado de cada columna:

- **Unnamed**: 0: identificador del registro
- **host_response_rate**: tasa de respuesta del anfitrión (en %)
- **host_acceptance_rate**: tasa de aceptación del anfitrión (en %)
- **host_listings_count**: número de huéspedes alojados
- **accommodates**: capacidad del alojamiento
- **room_type**: tipo de habitación (apartamento entero/habitación privada/habitación compartida)
- **bedrooms**: número de habitaciones
- **bathrooms**: número de baños
- **beds**: número de camas
- **price**: precio por noche (en dólares)
- **minimum_nights**: número mínimo de noches
- **maximum_nights**: número máximo de noches
- **number_of_reviews**: número mínimo de opiniones
- **latitude**: latitud
- **longitude**: longitud
- **city**: ciudad
- **zipcode**: código postal
- **state**: estado
- **tidy_price**: precio por noche (en dólares)

### Cabecera del dataset

| | Unnamed: 0 | host_response_rate | host_acceptance_rate | host_listings_count | accommodates | room_type | bedrooms | bathrooms | beds |
|---|---|---|---|---|---|---|---|---|---|
| 0 | 1 | 92% | 91% | 26 | 4 | Entire home/apt | 1 | 1.0 | 2 |
| 1 | 2 | 90% | 100% | 1 | 6 | Entire home/apt | 3 | 3.0 | 3 |
| 2 | 3 | 90% | 100% | 2 | 1 | Private room | 1 | 2.0 | 1 |
| 3 | 4 | 100% | NaN | 1 | 2 | Private room | 1 | 1.0 | 1 |
| 4 | 5 | 92% | 67% | 1 | 4 | Entire home/apt | 1 | 1.0 | 1 |

### Cabecera del dataset (continuación)

| price | minimum_nights | maximum_nights | number_of_reviews | latitude | longitude | city | zipcode | state | tidy_price |
|---|---|---|---|---|---|---|---|---|---|
| $160.00 | 1 | 1125 | 0 | 38.890046 | -77.002808 | Washington | 20003 | DC | 160 |
| $350.00 | 2 | 30 | 65 | 38.880413 | -76.990485 | Washington | 20003 | DC | 350 |
| $50.00 | 2 | 1125 | 1 | 38.955291 | -76.986006 | Hyattsville | 20782 | MD | 50 |
| $95.00 | 1 | 1125 | 0 | 38.872134 | -77.019639 | Washington | 20024 | DC | 95 |
| $50.00 | 7 | 1125 | 0 | 38.996382 | -77.041541 | Silver Spring | 20910 | MD | 50 |

# 2. Integración y selección de los datos de interés a analizar

Para realizar los análisis es necesario realizar las siguientes transformaciones preliminares:

- **Unnamed: 0**: **renombrar** la columna como "id".
- **host_response_rate** y **host_acceptance_rate**: eliminar signo de porcentaje para **convertir** la variable a tipo *float*.
- **price**: eliminar signo de dólar y **convertir** a *float*.
- **latitude** y **longitude**: **fundir** las columnas para crear una sola con una tupla que represente las coordenadas.
- **city**: **filtrar** los registros de la ciudad de Washington, en la que centraremos el análisis.
- **zipcode, state** y **tidy_price**: **eliminar** estas columnas.

### Sintaxis de las transformaciones

```
# Realizamos las transformaciones indicadas en cada columna
df = df.rename(columns={"Unnamed: 0": "id"})
df['host_response_rate'] = df['host_response_rate'].str.rstrip('%').astype('float')
df['host_acceptance_rate'] = df['host_acceptance_rate'].str.rstrip('%').astype('float')
df['price'] = df['price'].str.replace(',','',regex=True).str.replace('$','',regex=True).astype(float)
df['coordenates'] = list(zip(df['longitude'],df['latitude']))
df = df[df['city'].str.contains('Washington')]
df = df.drop(['zipcode', 'state', 'tidy_price'], axis=1)
```

Además, **enriqueceremos el dataset con una nueva columna** *neighborhood*. Esta columna contendrá el barrio en el que se ubica la vivienda. Para ello, utilizaremos un fichero *.geojson* que contiene las coordenadas de los barrios de la ciudad de Washington. Dicho fichero puede descargarse en la plataforma *opendatadc*.

### Sintaxis de la integración del fichero geojson

```
# Definimos una función que devuelve el barrio de Washington DC en el que se encuentra una coordenada
def get_nbh(point, js):
    for feature in js['features']:
        polygon = shape(feature['geometry'])
        if polygon.contains(point):
            return(feature["properties"]["NBH_NAMES"])

# Cargamos el geojson
with open('data/Neighborhood_Clusters.geojson') as f:
    js = json.load(f)


# Comprobamos a qué barrio pertenece cada vivienda
neighborhood = []
for point in df.coordenates:
    point = Point(point[0], point[1])
    neighborhood.append(get_nbh(point, js))

# Añadimos una nueva columna al dataframe
df["neighborhood"] = neighborhood
```

Conociendo las coordenadas de cada vivienda podemos visualizar el conjunto de viviendas en el mapa de la ciudad y, de este modo, **detectar visualmente los barrios caros y baratos**. Para ello, hemos transformado los precios a escala logarítmica, que refleja mejor la naturaleza dicotómica de la clasificación. El objetivo de este gráfico es generar una nueva variable (*expensive_neighborhood*) a partir de la información visual que identifiquemos. La idoneidad de dicha columna será contrastada en el Ejercicio 4.

### Sintaxis para la creación del mapa

```
gdf = gpd.read_file('data/Neighborhood_Clusters.geojson')
gdf_houses = gpd.GeoDataFrame(
    df, geometry=gpd.points_from_xy(df.longitude, df.latitude))
gdf_houses["price_log"] = np.log10(gdf_houses["price"])
m = gdf.explore(tooltip="NBH_NAMES", color="white")
gdf_houses.explore(m=m,
                   tooltip="neighborhood",
                   column="price_log",
                   color="price_log",
                   cmap="seismic",
                   legend=False,
                   marker_kwds=dict(radius=1, fill=True))

folium.TileLayer('Stamen Toner', control=True).add_to(m)  # use folium to add alternative tiles
folium.LayerControl().add_to(m)  # use folium to add layer control
display(m)
```

### Mapa interactivo con el precio de los apartamentos

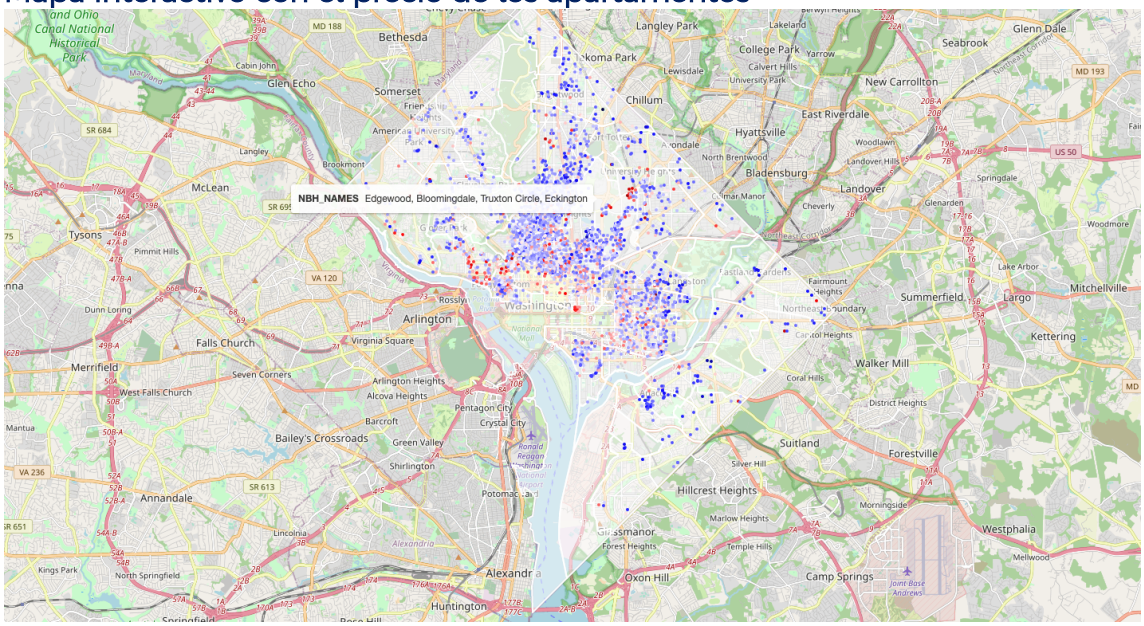


Como vemos en el gráfico, hay algunos barrios que presentan una **alta concentración de puntos rojos** (podemos pasar el ratón por encima del barrio o de la vivienda para identificar el barrio), como:

- Capitol Hill, Lincoln Park
- Georgetown, Burleith/Hillandale
- West End, Foggy Bottom, GWU
- Downtown, Chinatown, Penn Quarters, Mount Vernon Square, North Capitol Street

Estos serán los barrios que identifiquemos como caros, para lo que crearemos una nueva variable.

### Creación de la nueva variable *expensive_nbh*

```
expensive_nbh = ['Capitol Hill, Lincoln Park',
                 'Georgetown, Burleith/Hillandale',
                 'West End, Foggy Bottom, GWU',
                 'Downtown, Chinatown, Penn Quarters, Mount Vernon Square, North Capitol Street']
df['expensive_nbh'] = df.neighborhood.apply(lambda x: 1 if x in expensive_nbh else 0)
```

Tras las transformaciones, el *dataset* cuenta con 13 columnas y 3644 filas.

### Cabecera del dataset tras las transformaciones

| | host_response_rate | host_acceptance_rate | host_listings_count | accommodates | room_type | bedrooms | bathrooms | beds | price | minimum_nights | maximum_nights | number_of_reviews | expensive_nbh |
|---|---|---|---|---|---|---|---|---|---|---|---|---|---|
| 0 | 92.0 | 91.0 | 26 | 4 | Entire home/apt | 1 | 1.0 | 2 | 160.0 | 1 | 1125 | 0 | 1 |
| 1 | 90.0 | 100.0 | 1 | 6 | Entire home/apt | 3 | 3.0 | 3 | 350.0 | 2 | 30 | 65 | 1 |
| 3 | 100.0 | NaN | 1 | 2 | Private room | 1 | 1.0 | 1 | 95.0 | 1 | 1125 | 0 | 0 |
| 5 | 100.0 | 100.0 | 1 | 4 | Entire home/apt | 2 | 1.0 | 4 | 99.0 | 1 | 1125 | 0 | 0 |
| 6 | 100.0 | NaN | 1 | 4 | Entire home/apt | 2 | 2.0 | 2 | 100.0 | 3 | 1125 | 0 | 0 |

# 3. Limpieza de datos

## 3.1. Elementos nulos

Consultamos los elementos nulos y vemos que únicamente tienen valores perdidos las variables *host_acceptance_rate* (16.30%) y *host_response_rate* (11.47%). En este caso, no consideramos los valores igual a 0 como nulos ya que pueden tener un significado en la realidad; como apartamentos que no han recibido ninguna valoración, apartamentos que no tienen cama porque tienen otra alternativa (e.g., sofá), etc.

La imputación de valores perdidos es un tema controvertido ya que no hay una única recomendación sobre el porcentaje máximo a partir del cual no se deben imputar valores perdidos. No obstante, existe cierto consenso en que se puede realizar la imputación si éstos no representan más del 20% de los registros. En este caso, por tanto, imputaremos los valores en ambas variables siguiendo el método kNN. No obstante, realizaremos dicha transformación tras tratar los valores atípicos y extremos.

### Consulta de valores nulos

```
# Consulta de elementos nulos (expresado en porcentaje)
display(pd.DataFrame(df.isnull().sum() / len(df)*100).rename({0:"Nulos"}, axis=1))
```

| | Nulos |
|---|---|
| host_response_rate | 11.470911 |
| host_acceptance_rate | 16.300768 |

## 3.2. Valores atípicos y extremos

Para detectar los valores atípicos aplicamos la función *describe* mediante la cual podemos ver los principales estadísticos descriptivos de las variables cuantitativas.

Esta función es muy útil ya que nos permite identificar posibles errores como porcentajes superiores a 100 o precios negativos. Visualizamos también las frecuencias en la variable categórica *room_type*, para comprobar si hay algún valor que sea necesario integrar (por ejemplo, dos cadenas aludiendo a un mismo concepto).

### Exploración de los estadísticos descriptivos

| | host_response_rate | host_acceptance_rate | host_listings_count | accommodates | bedrooms | bathrooms | beds | price | minimum_nights | maximum_nights | number_of_reviews | expensive_nbh |
|---|---|---|---|---|---|---|---|---|---|---|---|---|
| count | 3226.000000 | 3050.000000 | 3644.000000 | 3644.000000 | 3644.000000 | 3644.000000 | 3644.000000 | 3644.000000 | 3644.000000 | 3.644000e+03 | 3644.000000 | 3644.00000 |
| mean | 91.400806 | 86.376393 | 12.899286 | 3.197859 | 1.209111 | 1.258095 | 1.648738 | 149.148463 | 2.233260 | 5.928732e+05 | 15.170692 | 0.19978 |
| std | 14.886035 | 21.264548 | 62.394902 | 2.006053 | 0.841332 | 0.587408 | 1.186481 | 137.864318 | 3.623274 | 3.557498e+07 | 29.307778 | 0.39989 |
| min | 7.000000 | 0.000000 | 1.000000 | 1.000000 | 0.000000 | 0.000000 | 1.000000 | 10.000000 | 1.000000 | 1.000000e+00 | 0.000000 | 0.00000 |
| 25% | 90.000000 | 79.000000 | 1.000000 | 2.000000 | 1.000000 | 1.000000 | 1.000000 | 85.000000 | 1.000000 | 1.097500e+02 | 1.000000 | 0.00000 |
| 50% | 100.000000 | 98.000000 | 1.000000 | 2.000000 | 1.000000 | 1.000000 | 1.000000 | 115.000000 | 2.000000 | 1.125000e+03 | 4.000000 | 0.00000 |
| 75% | 100.000000 | 100.000000 | 3.000000 | 4.000000 | 1.000000 | 1.000000 | 2.000000 | 165.000000 | 3.000000 | 1.125000e+03 | 16.000000 | 0.00000 |
| max | 100.000000 | 100.000000 | 480.000000 | 16.000000 | 10.000000 | 8.000000 | 16.000000 | 2822.000000 | 180.000000 | 2.147484e+09 | 362.000000 | 1.00000 |

```
# Exploración de las distribuciones de la variable categórica
display(pd.DataFrame(df['room_type'].value_counts()))
```

| | room_type |
|---|---|
| Entire home/apt | 2366 |
| Private room | 1183 |
| Shared room | 95 |

En la exploración, observamos anomalías en la siguiente variable:

- **maximum_nights**: valor medio de 35,574,980.51 y máximo de 2,147,483,647.00

Respecto del resto de variables, aunque puedan presentar *outliers*, estas (posibles) anomalías podrían representar valores, si bien extremos, reales. No obstante, siguiendo una de las recomendaciones más extendidas, consideraremos *outliers* a eliminar **aquellos registros que se alejen más de tres desviaciones típicas de la media en las variables**: *price*, *minimum_nights*, *maximum_nights* y *number_of_reviews* (nótese que, mediante la operación de borrado, se eliminan las anomalías ya identificadas en la columna *maximum_nights*).

### Tratamiento de los valores atípicos y extremos

```
# Tratamiento de los valores atípicos y extremos
cols = ['price','minimum_nights',
        'maximum_nights','number_of_reviews']

def del_outliers(df, cols, std=3):
    for c in cols:
        lim_inf = df[c].mean()-3*df[c].std()
        lim_sup = df[c].mean()+3*df[c].std()
        df = df[df[c].between(lim_inf, lim_sup)]
        return df

df = del_outliers(df, cols)
```

Después de eliminar los valores extremos, el *dataset* cuenta con un total de 3584 filas. Tras el tratamiento de los valores atípicos y extremos, podemos **imputar los valores perdidos** mediante el método de los *k* vecinos más cercanos.

### Imputación de valores perdidos mediante kNN

```
# Imputación de valores perdidos
imputer = KNNImputer()
df_knn = df.drop(['room_type'], axis=1)

df_knn = pd.DataFrame(imputer.fit_transform(df_knn))

df['host_response_rate'] = df_knn[0].tolist()
df['host_acceptance_rate'] = df_knn[1].tolist()
```

### Comprobación de la imputación

| | Nulos |
|---|---|
| host_response_rate | 0 |
| host_acceptance_rate | 0 |
| host_listings_count | 0 |
| accommodates | 0 |
| room_type | 0 |
| bedrooms | 0 |
| bathrooms | 0 |
| beds | 0 |
| price | 0 |
| minimum_nights | 0 |
| maximum_nights | 0 |
| number_of_reviews | 0 |
| expensive_nbh | 0 |

# 4. Análisis de datos

### 4.1. Selección de los grupos de datos

En el segundo apartado de la actividad, hemos visualizado la distribución de viviendas por barrios de la ciudad de Washington y hemos identificado visualmente aquellos barrios que, aparentemente, contenían precios por noche más altos. Hemos denominado *barrios caros* a dichos barrios, y hemos añadido esta información a nuestro *dataset*. No obstante, es muy conveniente comprobar si la identificación realizada es o no correcta y si, por lo tanto, podemos afirmar que los precios son, por norma general, más altos en los barrios que hemos identificado como caros. Para ello, primero **separaremos los precios en dos conjuntos: precios de barrios baratos y precios de barrios caros.**

### Selección de los grupos

```
precios_barrios_baratos = df[df.expensive_nbh==0].price
precios_barrios_caros = df[df.expensive_nbh==1].price
```

### 4.2. Comprobación de la normalidad y homogeneidad de varianza

En función del contraste de hipótesis que deseemos efectuar, utilizaremos uno u otro estadístico de contraste (*t test*, *Welch t test*, prueba Chi cuadrado...). Algunas de estas pruebas son paramétricas, por lo que conviene conocer la distribución de

los datos y si puede asumirse que las muestras a comparar comparten o no la misma varianza. Comenzamos visualizando los gráficos QQ de cada muestra.

### Gráficos QQ de cada muestra

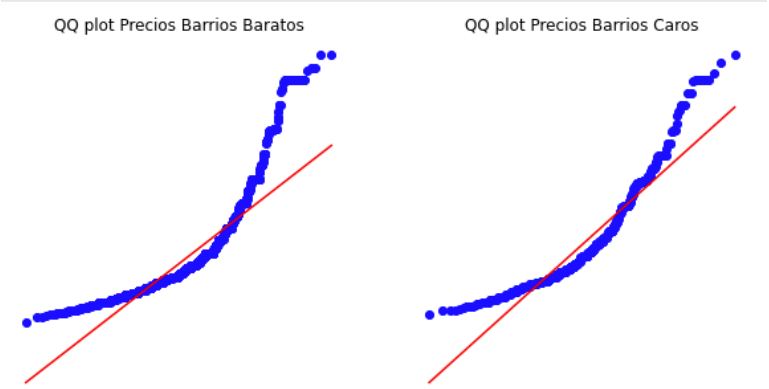


Como vemos, **no parece en absoluto que los datos estén distribuidos normalmente**. En cualquier caso, realizaremos el **test de Shapiro-Wilk**.

### Comprobación de normalidad

```
def is_normal(v):
    stat, p = stats.shapiro(v)
    print("Estadístico: {}\nP valor:{}".format(round(stat, 2), round(p, 2)))
    if p > 0.05:
        print("Probablemente normal")
    else:
        print("Probablemente no normal")


print("Distribución precios barrios baratos:")
is_normal(precios_barrios_baratos)

print("\nDistribución precios barrios caros:")
is_normal(precios_barrios_caros)
```

```
Distribución precios barrios baratos:
Estadístico: 0.8
P valor:0.0
Probablemente no normal

Distribución precios barrios caros:
Estadístico: 0.88
P valor:0.0
Probablemente no normal
```

Habida cuenta de los resultados, concluimos que **los datos no se distribuyen normalmente**. Para determinar **la homocedasticidad o heterocedasticidad** de los datos utilizaremos el **test de Levene**.

### Comprobación de homocedasticidad

```
def same_variance(x1, x2):
    stat, p = stats.levene(x1, x2)
    print("Estadístico: {}\nP valor:{}".format(round(stat, 2), round(p, 2)))
    if p > 0.05:
        print("Probablemente misma varianza")
    else:
        print("Probablemente distinta varianza")

same_variance(precios_barrios_baratos, precios_barrios_caros)
```

```
Estadístico: 51.0
P valor:0.0
Probablemente distinta varianza
```

Del test anterior inferimos que los datos tienen **distinta varianza**.

## 4.3. Aplicación de pruebas estadísticas

### 4.3.1 ¿Es realmente más alto el precio/noche en los barrios que hemos identificado como caros?

Nos interesa determinar si el precio medio por noche en los barrios que creemos que son caros es realmente superior al precio medio por noche en los barrios que hemos identificado como baratos. La **hipótesis nula** es el **precio medio por noche es igual en los barrios identificados como baratos que en los identificados como caros**, mientras que la hipótesis alternativa es **el precio medio por noche es inferior en los barrios identificados como baratos que en los identificados como caros**. Tenemos, por lo tanto, el siguiente contraste de hipótesis:

$$H_0 = \mu_{baratos} = \mu_{caros}$$

$$H_1 = \mu_{baratos} < \mu_{caros}$$

Tenemos, por lo tanto, que contrastar las medias de **dos muestras que no se distribuyen normalmente y que no comparten la misma varianza**. Ahora bien, respecto de la primera consideración (distribución no normal), quizás podamos aplicar el teorema del límite central en caso de que contemos con un número suficientemente alto de observaciones. Comprobemos, pues, este extremo.

### Tamaño muestral de los grupos

```
print("Observaciones barrios baratos: {}".format(len(precios_barrios_baratos)))
print("Observaciones barrios caros: {}".format(len(precios_barrios_caros)))
```

```
Observaciones barrios baratos: 2879
Observaciones barrios caros: 705
```

En los dos casos tenemos un elevado número de observaciones, en cualquier caso, más de treinta, por lo que podemos aplicar el **teorema del límite central**, según el cual la distribución de las **medias muestrales** de una población se distribuye normalmente cuando tenemos un número lo suficientemente elevado de observaciones (más de treinta, en la práctica). Dicha distribución de las medias muestrales tiene **media igual a la poblacional** y **desviación típica** $\sigma/\sqrt{(n)}$.

Por lo tanto, en virtud de este teorema, tenemos dos distribuciones normales (las distribuciones de las medias muestrales de cada conjunto de precios) con media

$\mu_{baratos}$ y $\mu_{caros}$; y con desviación típica $\sigma_{baratos}/\sqrt{(n_{baratos})}$ y $\sigma_{caros}/\sqrt{(n_{caros})}$, respectivamente.

En consecuencia, podemos aplicar la **prueba *t test de Welch***, una prueba no paramétrica que se utiliza para determinar si dos conjuntos de datos que se distribuyen normalmente tienen distinta media. A diferencia de la prueba *t* tradicional, la variante de Welch no asume la homocedasticidad de los datos, por lo que podemos aplicarlo perfectamente.

### Test de Welch

```
def welch_test(x1, x2, alt):
    stat, p = stats.ttest_ind(x1, x2, equal_var = False, alternative=alt)
    print("Estadístico: {}\nP valor:{}".format(round(stat, 2), round(p, 2)))
    if p > 0.05:
        print("Se acepta la hipótesis nula")
    else:
        print("Se rechaza la hipótesis nula")

welch_test(precios_barrios_baratos, precios_barrios_caros, "less")
```

```
Estadístico: -11.93
P valor:0.0
Se rechaza la hipótesis nula
```

Para la prueba *t* de *Welch* hemos obtenido un *p* valor de 0, por lo que para cualquier nivel de significancia **podemos rechazar la hipótesis nula**, lo que implica que, efectivamente, **el precio medio es mayor en los barrios que hemos identificado visualmente como caros**, por lo que la introducción de la variable *expensive_nbh* está plenamente justificada.

### 4.3.2. Correlación lineal entre las variables independientes y la variable respuesta

Para determinar qué variables predictoras están más fuertemente correlacionadas con la variable respuesta, podemos calcular el **coeficiente de correlación lineal de Pearson** entre cada predictor y la respuesta.

### Correlación con la variable respuesta (*price*)

| | Coef Pearson |
|---|---|
| accommodates | 0.586298 |
| bedrooms | 0.569235 |
| beds | 0.486227 |
| bathrooms | 0.485796 |
| room_type_Entire home/apt | 0.436862 |
| room_type_Private room | -0.397048 |
| host_listings_count | 0.243117 |
| expensive_nbh | 0.219341 |
| room_type_Shared room | -0.140928 |
| number_of_reviews | -0.075510 |
| host_acceptance_rate | -0.065567 |
| host_response_rate | -0.030606 |
| maximum_nights | 0.028090 |
| minimum_nights | 0.025945 |

Vemos que, según el coeficiente de correlación de Pearson, **las variables más relacionadas con el precio son la capacidad del alojamiento, el número de**

**huéspedes, el número de habitaciones, el número de camas, el número de baños, el tipo de alojamiento (vivienda, habitación...) y el tipo de barrio (caro o barato)**. Podemos graficar la correlación lineal entre las variables numéricas, ordinales o continuas, y la variable respuesta mediante **diagramas de puntos**.


Asimismo, y con el fin de detectar la **colinealidad**, en caso de haberla, calculamos la correlación lineal entre las variables numéricas predictoras, para lo que generamos una matriz de correlación.

### Correlación entre variables predictoras

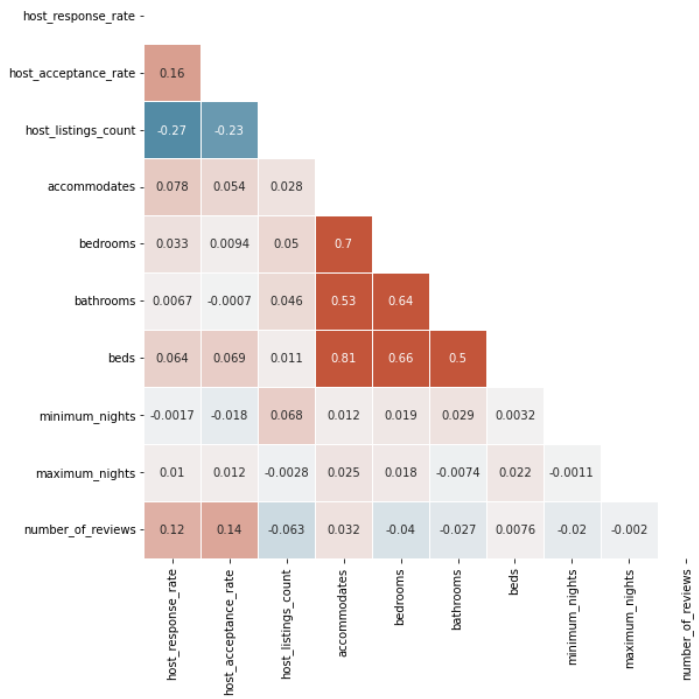


Vemos que la variable *accommodates* está fuertemente correlacionada con *beds*. Dado que dicha correlación es superior a 0.8, podemos **eliminar una de las dos variables** antes de implementar la regresión lineal múltiple. Dado que *accommodates* está más correlacionada con *price* que *beds*, eliminamos esta última.

### 4.3.3. Regresión lineal múltiple

Por último, definiremos a partir de los datos un **modelo de regresión lineal múltiple** que nos permita predecir futuros precios por noche.

### Regresión lineal múltiple

```
reg = LinearRegression().fit(X, y)
print("El coeficiente de determinación del modelo es: {}".format(round(reg.score(X, y), 2)))
```

```
# Aislamos y mostramos los coeficientes del hiperplano
intercept = round(reg.intercept_, 2)
coefs = dict(zip(X.columns, np.round_(reg.coef_, 1)))
```

```
print("El valor del intercepto es: {}".format(intercept))
print("El valor de los coeficientes es: {}".format(coefs))
```

```
El valor del intercepto es: 22.63
El valor de los coeficientes es: {'host_response_rate': 0.0, 'host_acceptance_rate': -0.1, 'host_listings_
count': 0.2, 'accommodates': 8.3, 'bedrooms': 28.4, 'bathrooms': 27.8, 'minimum_nights': -0.5, 'maximum_ni
ghts': 0.0, 'number_of_reviews': -0.1, 'expensive_nbh': 28.9, 'room_type_Entire home/apt': 37.0, 'room_typ
e_Private room': -5.2, 'room_type_Shared room': -31.8}
```

El **coeficiente de determinación** es de **0.54**, lo que implica que el modelo solo explica algo más de la mitad del 50% de la varianza de los datos. Si solo atendemos a este indicador, podemos concluir que **el modelo es moderadamente predictivo**, aunque también podríamos optar por otras métricas quizás más esclarecedoras, como el error estándar del modelo.

Por lo tanto, **debemos estimar el precio por noche a partir del siguiente modelo:**

$$\hat{y} = 22.63 + 37x_{entire} - 31.8x_{sharedroom} + 28.4x_{bedrooms} + 28.9x_{expensivenbh} + 27.8x_{bathrooms} + 8.3x_{accom} - 5.2x_{privateroom} - 0.5x_{minnights} + 0.2x_{listcount} - 0.1x_{acceptrate} - 0.1x_{revisions} - 0x_{maxnights} - 0x_{resprate}$$

# 5. Resolución del problema

A partir de los resultados obtenidos, podemos extraer las siguientes conclusiones:

- Hay **barrios o zonas de Washington DC donde el alojamiento en Airbnb es significativamente más caro** que en otros. Estos barrios son céntricos y están a orillas del río Potomac. Son Capitol Hill, Lincoln Park, Georgetown, Burleith/Hillandale, West End, Foggy Bottom, GWU, Downtown, Chinatown, Penn Quarters, Mount Vernon Square y North Capitol Street.

- El precio por noche del alojamiento queda fundamentalmente determinado por la **capacidad del alojamiento**, el número de **huéspedes**, de **habitaciones**, **camas** y **baños** de la vivienda; así como por el tipo de alojamiento (más caro en apartamento, más barato en habitación, privada o compartida) y por el barrio.

- Mediante una regresión lineal múltiple **se ha podido generar un modelo de predicción de precios que representa algo más de la mitad de la varianza de los datos**. Si atendemos exclusivamente al coeficiente de determinación, el modelo, aunque moderadamente predictivo, no es muy bueno. Puede haber dos motivos: o bien las variables independientes no son lo suficientemente predictivas o bien la relación entre la variable respuesta y las variables predictoras debería estimarse a partir de un modelo no lineal.

# Referencias y contribuciones

Calvo M., Pérez D., Subirats L (2019). *Introducción a la limpieza y análisis de los datos*. Editorial UOC.

Jason W. Osborne (2010). Data Cleaning Basics: Best Practices in Dealing with Extreme Scores. *Newborn and Infant Nursing Reviews; 10* (1). 1527-3369.

Jiawei Han, Micheine Kamber, Jian Pei (2012). *Data mining: concepts and techniques*. Morgan Kaufmann.

Kaggle (2020). *tidy_dc_airbnb*. Recuperado de https://www.kaggle.com/code/dehaozhang/stacking-ensemble/data?select=tidy_dc_airbnb.csv

McKinney, W. (2012). *Python for Data Analysis*. O'Reilley Media, Inc.

Megan Squire (2015*). Clean Data*. Packt Publishing Ltd.

Subirats-Maté, L., Pérez-Trenard. D.O. y Calvo-González, M. *Introducción al ciclo de vida de los datos*. Editorial UOC.

## Contribuciones

| CONTRIBUCIONES | FIRMAS |
|---|---|
| Investigación previa |  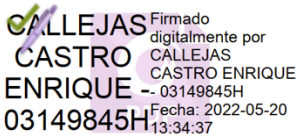  |
| Redacción de las respuestas |  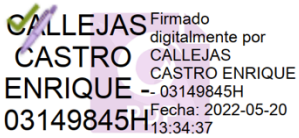  |
| Desarrollo del código | 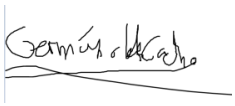 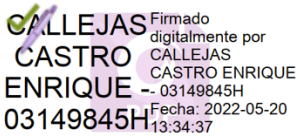  |